


# **Business Intelligence**

Knowledge Discovery in Databases


**Prof. Leandro Guerra** 

E-mail: leandro.guerra@outspokenmarket.com.br IG: @leandrowar




# **Business Intelligence Nível de Maturidade**

### Relembrar é viver...




Ele é constituído de seis etapas

- Entendimento do Negócio
- Entendimento dos Dados
- Preparação dos Dados
- Modelagem
- Avaliação
- Entrega




# **Business Intelligence**& Data Mining



<sup>\*</sup>Introduction to KDD and data mining - http://www.mimuw.edu.pl/~son/datamining/DM/1-intro.pdf

### **Knowledge Discovery in Databases**

"É o processo de descobrir conhecimento útil de uma ou mais bases de dados. É um processo amplamente utilizado, que inclui preparação dos dados, hieginação, seleção e técnicas de data mining para encontrar padrões que possam ser interpretados e transformado em conhecimento, auxiliando o processo de tomada de decisão"



<sup>\*</sup>Etapas dos processo de KDD (Fayyad et. al. 1996)

# KDD Etapas

### 1 – Entendimento do Negócio

# 3 – Data *cleaning* e pré-processamento

- Tratamento de outliers
- Tratamento de missings

# 5 – Escolha da tarefa de data mining

- Classificação
- Regressão
- Agrupamento (Clustering)
- Associação

### 6 – Escolha do algoritmo

2 – Entendimento e escolha dos dados

4 - Featuring Engineering e Feature Selection

7 - Execução


8 – Interpretação dos resultados



## Etapa 5 – Escolha da tarefa de data mining

**Exemplo: Customer Churn** 


Valor da Fatura



## Etapa 5 – Escolha da tarefa de data mining

Exemplo: Regressão Linear


Valor da Fatura



## Etapa 5 – Escolha da tarefa de data mining

Exemplo: Classificação Linear


Valor da Fatura



## Etapa 5 – Escolha da tarefa de data mining

Exemplo: Classificação Não-Linear


Valor da Fatura



## Etapa 5 – Escolha da tarefa de data mining


Exemplo: Clustering – K-Means

Valor da Fatura




# Clustering no R K-Means – Demonstração do Algoritmo

1) k initial "means" (in this case k=3) are randomly generated within the data domain (shown in color).




 k clusters are created by associating every observation with the nearest mean. The partitions here represent the Voronoi diagram generated by the means.

### Demonstration of the standard algorithm




 The centroid of each of the k clusters becomes the new mean.



 Steps 2 and 3 are repeated until convergence has been reached.

```
#Selecionando o diretorio de trabalho
source('C:/Users/Leandro/Google Drive/FMU/kmeans.R')
**********
### Preparação dos dados ###
**********
#Limpando o environment
rm(list=ls())
#Limpando os NAs
base <- na.omit(iris)</pre>
#Padronizando as variáveis
base2 <- data.frame(scale(base[,1:4]))</pre>
base2$Species <- base$Species
base <- base2
#Determinando o número de clusters
wss <- (nrow(base)-1) *sum(apply(base[,1:4],2,var))
#15 será o número de Cluster máximo para teste
for (i in 2:15) {
      wss[i] <- sum(kmeans(base[,1:4],centers=i)$withinss)
#Cria o gráfico mostrando o número de clusters x erro
plot(1:15, wss, type="b", xlab="Número de Clusters",
     ylab="Soma dos quadradados - Erro", main = "Clusters x Erro")
```


### Clusters x Erro



### > table(base\$kmedias.cluster,base\$Species)

	setosa	versicolor	virginica
1	0	11	36
2	0	39	14
3	50	0	0

### Cluster - Espécies




Component 1 These two components explain 94.19 % of the point variability.

# Clustering no R Dendograma

```
**********************
### Criando um Dendograma ###
**********************
#Base mtcars
#Limpando os NAs
base mtcars <- na.omit(mtcars)</pre>
#Padronizando as variáveis
base mtcars <- scale(base mtcars)
#Cria uma clusterização hierarquica
#Cria a matriz de distâncias
distancia <- dist(base mtcars, method = "euclidean")
dendo <- hclust(distancia, method="ward.D")
#Plota o dendograma
plot (dendo)
#Divide o dendograma em 5 grupos
grupos <- cutree (dendo, k=5)
#Desenha uma borda azul
rect.hclust(dendo, k=8, border="blue")
```


# Clustering no R Dendograma


### **Cluster Dendrogram**



distancia hclust (\*, "ward.D")

# Clustering no R Dendograma





distancia hclust (\*, "ward.D")

# **Voltando ao Kaggle... Otto Group Product Classification Challenge**



# Voltando ao Kaggle... **Otto Group Product Classification Challenge**

896

Leandro Guerra

0.55719

Sat, 04 Apr 2015 12:46:45

Your Best Entry ↑

You improved on your best score by 0.03766.

You just moved up 178 positions on the leaderboard.







1054

Leandro Guerra

0.59485

Fri, 03 Apr 2015 19:22:33

**Your Best Entry** ↑


You improved on your best score by 14.72112.

You just moved up 597 positions on the leaderboard.











## Por onde começar? Árvore de Decisão?




Rattle 2015-mar-29 12:36:03 Leandro

# Random Forest Uma floresta?



## Random forest Decision Trees Ensemble



# Random forest Observações

Prós

Contras



# **Business Intelligence**